


Aplikace neuronových sítí


Konvoluční sítě

Dvourozměrná konvoluce



Pro každý výstupní pixel:


$$z_{uv} = \sum_{i=-k}^{+k} \sum_{j=-k}^{+k} w_{ij} x_{u+i, v+j} + b$$



$$z_{uv} = \mathbf{w}^T \mathbf{x}_{uv} + b$$

výstupní obrázek z
velikost závisí
na nastavení konvoluce

Demo



input image

$$\left(\begin{array}{ccc} 139 & + & 192 & + & 190 \\ \times 0.0625 & \times 0.125 & \times 0.0625 \end{array} \right.$$


$$+ \begin{array}{ccc} 139 & + & 191 & + & 197 \\ \times 0.125 & \times 0.25 & \times 0.125 \end{array}$$

$$+ \begin{array}{ccc} 149 & + & 191 & + & 190 \\ \times 0.0625 & \times 0.125 & \times 0.0625 \end{array} \right)$$

$$= \begin{array}{c} 179 \end{array}$$

kernel:

blur ▼




output image

okraje?

Odkaz: <http://setosa.io/ev/image-kernels/>

Padding

Jak se vypořádat s okraji?



Obrázek např. “nastavíme” nulami
→ tzv. zero padding

6.0	14.0	17.0
14.0	12.0	12.0
8.0	10.0	17.0


(výsledek je 3x3, protože
v příkladu stride=2)

Existují další způsoby: const, wrap, symm, ...


obrázky: https://github.com/vdumoulin/conv_arithmetic

Velikost výstupu v závislosti na paddingu


`scipy.signal.convolve2d(x, w, mode, ...)` $\Rightarrow$ výstup $Q \times Q$



$$\begin{aligned} Q &= M - (K - 1) \\ &= 4 - 3 + 1 \\ &= 2 \end{aligned}$$



$$\begin{aligned} Q &= M - (K - 1) + 2P \\ &= M \\ &= 5 \end{aligned}$$




$$\begin{aligned} Q &= M - (K - 1) + 2P \\ &= M + (K - 1) \\ &= 5 + 3 - 1 \\ &= 7 \end{aligned}$$


Velikost kroku

V anglické literatuře stride


$S = 1$



$S = 2$



$S = 2$ je to samé, jako když $S = 1$,
ale ponecháme pouze každý S -tý výstup:





Vidíme tedy, že velikost výstupu
se krokem S dělí

(mezery jsou ve výstupu)

Velikost výstupu konvoluce


$$Q = \left\lfloor \frac{M + 2P - K}{S} \right\rfloor + 1$$



$$Q = \left\lfloor \frac{5 + 2 \cdot 0 - 3}{2} \right\rfloor + 1 = 2$$


$$Q = \left\lfloor \frac{5 + 2 \cdot 1 - 3}{2} \right\rfloor + 1 = 3$$

“Když to nevyjde hezky”:



$$Q = \left\lfloor \frac{6 + 2 \cdot 1 - 3}{2} \right\rfloor + 1 = 3$$


Vícekanálový vstup



rozměr filtru: 4x4x3

filtr vždy zahrnuje všechny vstupní kanály

Více konvolučních filtrů



Konvoluce jako vrstva v neurosíti

Váhy W jsou tensor tvaru

$$K \times K' \times C \times F$$

Bias b je vektor délky


$$F$$

Výstup má rozměr

$$Q = \left\lfloor \frac{M + 2P - K}{S} \right\rfloor + 1$$

Hyperparametry:

- velikost filtru K
- počet filtrů F
- padding (okraj) P
- stride (krok) S



Příklad: RGB 32x32x3, 10 5x5 filtrů, bez paddingu, stride=1

Váhy W jsou tensor tvaru

$$5 \times 5 \times 3 \times 10$$

Bias b je vector délky


10 (počet filtrů)

Počet parametrů vrstvy

$$5 \cdot 5 \cdot 3 \cdot 10 + 10 = 760$$

$\underbrace{5 \cdot 5 \cdot 3}_{\text{váhy}} + \underbrace{10}_{\text{biasy}} = 760$

Pro porovnání lineární vrstva $(32 \cdot 32 \cdot 3) \times (28 \cdot 28 \cdot 10)$
by měla $32 \cdot 32 \cdot 3 \cdot 28 \cdot 28 \cdot 10 \approx 24 \cdot 10^6$ parametrů!



Vstup tvaru

$$32 \times 32 \times 3$$

Výstup má rozměr

$$Q \times Q \text{ kde } Q = \left\lfloor \frac{32 + 2 \cdot 0 - 5}{1} \right\rfloor + 1 = 28$$

a hloubku

10 (počet filtrů)

Zpětný průchod konvoluce: gradient na váhy

- Dopředný průchod

$$z_{uv} = \sum_{i=1}^K \sum_{j=1}^K \sum_{c=1}^C w_{ijc} x_{\textcolor{green}{S}u+i, \textcolor{green}{S}v+j, c} + b$$


- Lokální gradient

$$\frac{\partial z_{uv}}{\partial w_{ijc}} = x_{i+Su, j+Sv, c}$$

- Celkový gradient na váhy


$$\begin{aligned} \frac{\partial L}{\partial w_{ijc}} &= \sum_{u=1}^Q \sum_{v=1}^Q \frac{\partial L}{\partial z_{uv}} \cdot \frac{\partial z_{uv}}{\partial w_{ijc}} \\ &= \sum_{\textcolor{red}{u}=1}^Q \sum_{\textcolor{red}{v}=1}^Q \bar{z}_{uv} \cdot x_{i+\textcolor{red}{S}u, j+\textcolor{red}{S}v, c} \end{aligned}$$

pokud $S > 1$:
“mezery” ve vstupu



- Zpětný průchod na váhy je tedy rovněž konvoluce!

Konvoluce jako lineární vrstva



konvoluci na obrázku lze zapsat maticově:

$2 \times 2 \rightarrow 4 \times 1$

$4 \times 4 \rightarrow 16 \times 1$

$$\begin{bmatrix} z_{11} \\ z_{12} \\ z_{21} \\ z_{22} \end{bmatrix} = \begin{bmatrix} w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} & 0 & 0 & 0 & 0 & 0 \\ 0 & w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} & 0 \\ 0 & 0 & 0 & 0 & 0 & w_{11} & w_{12} & w_{13} & 0 & w_{21} & w_{22} & w_{23} & 0 & w_{31} & w_{32} & w_{33} \end{bmatrix} \begin{bmatrix} x_{11} \\ x_{12} \\ x_{13} \\ \vdots \\ x_{42} \\ x_{43} \\ x_{44} \end{bmatrix}$$

... podobné lineární vrstvě

Zpětný průchod konvoluce: gradient na vstup


- Připomeňme, že pro lineární vrstvu
$$\mathbf{z} = \mathbf{W}\mathbf{x}$$

je gradient na vstup


$$\bar{\mathbf{x}} = \mathbf{W}^T \bar{\mathbf{z}}$$

- Zpětná propagace gradientu na vstup konvoluce je tedy opět konvoluce, jejíž lineární forma má transponovanou matici $\mathbf{W}$
- Odtud anglický název **transposed convolution**
- “Obrácená” konvoluce: z tvaru výstupu $\mathbf{z}$ na tvar vstupu $\mathbf{x}$
 - Nalezneme dokonce i název dekonvoluce: špatně, ve skutečnosti něco jiného


Ilustrace transponované konvoluce, stride=1



bez paddingu, stride=1




poloviční padding, stride=1




full padding, stride=1


Ilustrace transponované konvoluce, stride > 1



bez paddingu, stride=2



poloviční padding, stride=2




poloviční padding, stride=2
"když to nevyjde hezky"

mezery → anglický název **fractionally strided convolution**

Pooling


cílem zmenšit objem dat → méně paměti, tlak na kompresi příznakového prostoru



Max pooling

- Nejčastější forma poolingu
- Robustní vůči malému posunu vstupu

např. 2x2 max pooling, stride=2:



Počet parametrů: 0

výstup:

maximum přes každé okénko

vždy pouze pro jeden kanál vstupu →
redukuje pouze v x a y prostoru

příklad:

vstup: 32x32x3


výstup: 16x16x3

Max pooling: zpětný průchod


funkce max zapsána jinak: $z = \begin{cases} x_1 & \text{pokud } x_1 \geq x_i \forall x_i \in x \\ \vdots \\ x_D & \text{pokud } x_D \geq x_i \forall x_i \in x \end{cases} \Rightarrow \underline{\text{výběr prvku z pole}}$

(sub)gradient pak je: $\overline{x_d} = \begin{cases} 1 & \text{pokud } x_d \geq x_i \forall x_i \in x \\ 0 & \text{jinak} \end{cases}$

dopředný průchod



zpětný průchod



Spatial Batch Norm a další varianty





Figure 2. **Normalization methods.** Each subplot shows a feature map tensor, with N as the batch axis, C as the channel axis, and (H, W) as the spatial axes. The pixels in blue are normalized by the same mean and variance, computed by aggregating the values of these pixels.

Konvoluční síť (Convolutional Neural Network, CNN)

- zadefinováním konvoluce jako bloku v neurosíti nyní můžeme libovolně kombinovat s ostatními vrstvami



obrázek: <https://ch.mathworks.com/solutions/deep-learning/convolutional-neural-network.html>

Rozpoznávání MNIST čísel: LeNet-5 (1998)




Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

- první známá a úspěšná konvoluční síť
- architektura: CONV-POOL-CONV-POOL-FC-FC-FC

FC ... Fully Connected

[Lecun et al. \(1998\): GradientBased Learning Applied to Document Recognition](#)

Rozpoznávání MNIST čísel: LeNet-5 (1998)




Fig. 4. Size-normalized examples from the MNIST database.

MNIST ... 60000 obrázků čísel

animace: <http://yann.lecun.com/exdb/lenet/>

LeNet-5: dobové výsledky (error rate) na MNIST





Fig. 9. Error rate on the test set (%) for various classification methods. [deslant] indicates that the classifier was trained and tested on the deslanted version of the database. [dist] indicates that the training set was augmented with artificially distorted examples. [16x16] indicates that the system used the 16x16 pixel images. The uncertainty in the quoted error rates is about 0.1%.

Rozpoznávání ImageNet: Alexnet (2012)


1000 classes, Top-5 error [%]



top-5 ... správná třída musí být
do 5. místa dle skóre z výstupu
klasifikátoru

non-DNN modely

Alexnet (2012)




kolik parametrů má vrstva CONV1?

$$11 \cdot 11 \cdot 3 \cdot 96 = 34\,848$$

- architektura: CONV-POOL-NORM-CONV-POOL-NORM-CONV-CONV-CONV-FC-FC-FC
- “naškálovaná” LeNet-5

Alexnet (2012)




kolik parametrů má vrstva CONV2?

$$5 \cdot 5 \cdot 96 \cdot 256 = 614\,400$$

- architektura: CONV-POOL-NORM-CONV-POOL-NORM-CONV-CONV-CONV-FC-FC-FC
- “naškálovaná” LeNet-5

Alexnet (2012)



kolik parametrů má vrstva FC7?

$$4096 \cdot 4096 = 16\,777\,216 (!)$$


- architektura: CONV-POOL-NORM-CONV-POOL-NORM-CONV-CONV-CONV-FC-FC-FC
- “naškálovaná” LeNet-5

Alexnet (2012)


- [Krizhevsky, Sutskever, Hinton: “ImageNet Classification with Deep Convolutional Neural Networks”](#)
- Síť, která “nastartovala DNN/CNN revoluci”
- Autoři nevyvinuli žádný nový algoritmus, “pouze” ukázali, jak správně CNN používat
- Místo sigmoid aktivací přechod na ReLU
- Kromě klasické L2 regularizace navíc Dropout
- Výrazné umělé rozšiřování dat (data augmentation)
- Místo SGD → Momentum SGD
- Postupné snižování learning rate
- Trénováno na dvou GTX 580 celkem 5-6 dní

VGG (2014)

- [Simonyan, Zisserman: “Very Deep Convolutional Networks for Large-Scale Image Recognition”](#)
- Druhé místo ImageNet competition 2014
- Mnohem jednodušší architektura než vítěz (GoogLeNet)
- Velmi podobné AlexNet
- Místo 11x11 apod. konvolucí pouze 3x3
- Pouze 2x2 max-pooling
- Žádná lokální normalizace
- 16 a 19 vrstev
- VGG-16: 8.4 % top-5 error



Receptive field



výsledek konvoluce 3x3 nad druhou vrstvou závisí na 5x5 oblasti v první vrstvě

pro 3. vrstvu by to bylo 7x7, pro 4. vrstvu 9x9, atd.

jednotlivé neurony každé další vrstvy tedy popisují větší a větší část obrázku

VGG (2014)

- VGG tedy nahrazuje jedinou 7x7 konvoluci vrstvenými 3x3 konvolucemi
- Stejné “zorné pole” (receptive field)
- Méně parametrů:

$$3 \times (3 \times 3 \times C \times C) = 27C^2$$


vs

$$1 \times (7 \times 7 \times C \times C) = 49C^2$$

- Zároveň více nelinearit
- Výsledné “FC7” příznaky (4096D) lze použít i pro jiné úlohy (viz transfer learning)
- Poslední klasická CNN



ImageNet klasifikace




GoogLeNet (2014)

- [Szegedy et al.: Going Deeper with Convolutions](#)
- Navrženo s ohledem na výpočetní náročnost a celkový počet parametrů
- Skládá se z tzv. **Inception** modulů, které kombinují více typů konvolucí v jedné vrstvě (vychází z [Lin et al.: “Network in network”](#))



obrázek: <http://knowyourmeme.com/memes/we-need-to-go-deeper>


Inception modul v1




zero padding tak, aby výsledek konvoluce
měl vždy stejnou velikost (mode='same')

Optimalizace Inception modulu

[Szegedy et al.: Going Deeper with Convolutions](#)



(a) Inception module, naïve version



(b) Inception module with dimension reductions

Figure 2: Inception module



ve skutečnosti použita tato varianta


obrázek: <https://arxiv.org/abs/1409.4842>

1x1 konvoluce

vzpomeňme: filtr vždy zahrnuje všechny kanály


tzn., že i při 1x1 konvoluci (bez okolí) je výsledek stále lineární kombinací přes kanály

filtr je tedy $1 \times 1 \times C \rightarrow$ počet parametrů je $C \cdot F$



GoogLeNet (2014)

inception moduly



- vítěz ImageNet 2014 s 6.7 % top-5 error
- celkem 22 vrstev
- minimum fully-connected (lineárních) vrstev, téměř plně konvoluční síť
- 12x méně parametrů než AlexNet

loss na více místech sítě, ne pouze na vrchu

ResNet (2015)

- [He et al.: “Deep Residual Learning for Image Recognition”](#)
- Cílem návrhu být co nejhlubší → 152 vrstev!
- Vítěz ImageNet 2015 ve všech kategoriích
- Vítěz MS COCO challenge
- 3.6 % top-5 error na ImageNet: lepší než člověk (cca 5 %)
- Problém: přidávání vrstev pomáhá jen do určité chvíle, pak už ne
- Overfitting?

Příliš mnoho vrstev

Overfitting? Ne: kromě testovací chyby s více vrstvami roste i trénovací chyba!





Figure 1. Training error (left) and test error (right) on CIFAR-10 with 20-layer and 56-layer “plain” networks. The deeper network has higher training error, and thus test error. Similar phenomena on ImageNet is presented in Fig. 4.

Reziduální blok

- Podobně jako inception používá složitější bloky
- Výstup sestává ze součtu konvoluce a přímo mapovaného vstupu (identity)
- Síť se tedy učí pouze rezidua

$$\mathcal{F}(x) = \mathcal{H}(x) - x$$

- “Naučit se nuly je jednodušší než identitu”



$$\mathcal{H}(x) = \mathcal{F}(x) + x$$

Figure 2. Residual learning: a building block.

Bottleneck residual blok

Podobně jako u Inception i ResNet optimalizuje pomocí 1x1 bottleneck vrstev uvnitř reziduálních bloků






Figure 5. A deeper residual function $\mathcal{F}$ for ImageNet. Left: a building block (on 56×56 feature maps) as in Fig. 3 for ResNet-34. Right: a “bottleneck” building block for ResNet-50/101/152.




Téměř plně konvoluční

bez skrytých lineárních vrstev

VGG:




ResNet:




pouze lineární klasifikátor

Average pooling



DenseNet (2016)

- [Huang et al.: “Densely Connected Convolutional Networks”](#)
- Výstup vrstvy je připojen na vstup každé další vrstvy
- “ResNet do extrému”



SqueezeNet (2016)

- [Iandola et al: “SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size”](#)
- Cílem co nejmenší a nejefektivnější síť





Figure 1: Microarchitectural view: Organization of convolution filters in the **Fire module**. In this example, $s_{1 \times 1} = 3$, $e_{1 \times 1} = 4$, and $e_{3 \times 3} = 4$. We illustrate the convolution filters but not the activations.

SENet (2017)

- [Hu et al.: Squeeze-and-excitation Networks](#)
- Cílem nějak explicitně modelovat závislost kanálů



SENet (2017)

```
class SE_Block(nn.Module):
    "credits: https://github.com/moskomule/senet."
    def __init__(self, c, r=16):
        super().__init__()
        self.squeeze = nn.AdaptiveAvgPool2d(1)
        self.excitation = nn.Sequential(
            nn.Linear(c, c // r, bias=False),
            nn.ReLU(inplace=True),
            nn.Linear(c // r, c, bias=False),
            nn.Sigmoid()
        )

    def forward(self, x):
        bs, c, _, _ = x.shape
        y = self.squeeze(x).view(bs, c)
        y = self.excitation(y).view(bs, c, 1, 1)
        return x * y.expand_as(x)
```

plugin do existujících sítí

TABLE 4
Classification error (%) on CIFAR-10.


	original	SENet
ResNet-110 [14]	6.37	5.21
ResNet-164 [14]	5.46	4.39
WRN-16-8 [67]	4.27	3.88
Shake-Shake 26 2x96d [68] + Cutout [69]	2.56	2.12

TABLE 5
Classification error (%) on CIFAR-100.

	original	SENet
ResNet-110 [14]	26.88	23.85
ResNet-164 [14]	24.33	21.31
WRN-16-8 [67]	20.43	19.14
Shake-Even 29 2x4x64d [68] + Cutout [69]	15.85	15.41

MobileNetV2 (2018)


- [Sandler et al.: MobileNetV2: Inverted Residuals and Linear Bottlenecks](#)
- Depthwise separable konvoluce



MobileNetV2 (2018)


standardní ResNet

(a) Residual block



upravený ResNet s depthwise separable konvolucemi

(b) Inverted residual block



1. konvoluce je nahrazena depthwise separable verzí
2. místo bottlenecku expansion (= více kanálů)
3. čárkované konv. mapy neprocházejí nelinearitou

MobileNetV2 (2018)

Input	Operator	t	c	n	s
$224^2 \times 3$	conv2d	-	32	1	2
$112^2 \times 32$	bottleneck	1	16	1	1
$112^2 \times 16$	bottleneck	6	24	2	2
$56^2 \times 24$	bottleneck	6	32	3	2
$28^2 \times 32$	bottleneck	6	64	4	2
$14^2 \times 64$	bottleneck	6	96	3	1
$14^2 \times 96$	bottleneck	6	160	3	2
$7^2 \times 160$	bottleneck	6	320	1	1
$7^2 \times 320$	conv2d 1x1	-	1280	1	1
$7^2 \times 1280$	avgpool 7x7	-	-	1	-
$1 \times 1 \times 1280$	conv2d 1x1	-	k	-	-

Table 2: MobileNetV2 : Each line describes a sequence of 1 or more identical (modulo stride) layers, repeated n times. All layers in the same sequence have the same number c of output channels. The first layer of each sequence has a stride s and all others use stride 1. All spatial convolutions use 3×3 kernels. The expansion factor t is always applied to the input size as described in Table 1.

Network	Top 1	Params	MAdds	CPU
MobileNetV1	70.6	4.2M	575M	113ms
ShuffleNet (1.5)	71.5	3.4M	292M	-
ShuffleNet (x2)	73.7	5.4M	524M	-
NasNet-A	74.0	5.3M	564M	183ms
MobileNetV2	72.0	3.4M	300M	75ms
MobileNetV2 (1.4)	74.7	6.9M	585M	143ms

Table 4: Performance on ImageNet, comparison for different networks. As is common practice for ops, we count the total number of Multiply-Adds. In the last column we report running time in milliseconds (ms) for a single large core of the Google Pixel 1 phone (using TF-Lite). We do not report ShuffleNet numbers as efficient group convolutions and shuffling are not yet supported.

MNASNet (2018)

- [Tan et al.: MnasNet: Platform-Aware Neural Architecture Search for Mobile \(2018\)](#)
- Automatické hledání optimální architektury

Formulace úlohy jako optimalizace:

$$\underset{m}{\text{maximize}} \quad ACC(m) \times \left[\frac{LAT(m)}{T} \right]^w$$

$ACC(m)$... správnost modelu m

T ... cílová latence = čas potřebný pro dopředný průchod

$LAT(m)$... latence změřená přímo na mobilních telefonech

$w = -0.07$

Hledání není exhaustivní – základním stavebním kamenem je Inverted Residual Block (MobileNetV2), u něhož se pouze upravují hloubka a velikost filtru




Figure 1: An Overview of Platform-Aware Neural Architecture Search for Mobile.

EfficientNet (2019)

- [Tan, Le: EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks](#)




Figure 2. Model Scaling. (a) is a baseline network example; (b)-(d) are conventional scaling that only increases one dimension of network width, depth, or resolution. (e) is our proposed compound scaling method that uniformly scales all three dimensions with a fixed ratio.

EfficientNet (2019)

- [Tan, Le: EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks](#)
- Podobný úspěch jako v roce 2015 přinesl ResNet, stav poznání ve všech oblastech počítačového vidění
- **EfficientNet = neural architecture search + compound scaling**
- Neural architecture search (NAS) - formulováno jako reinforcement learning s expected reward (proximal policy)

$$ACC(m) \cdot [FLOPS(m)/T]^w$$

kde namísto latence je teoretická výpočetní náročnost ve floating point operacích

- Cílovým FLOPS je cca 400 MFLOPS

EfficientNet (2019)

- Automatickým hledáním NAS vznikne EfficientNet-B0, která má nějaké cílové FLOPs
- Nyní chceme větší síť, ale bez NAS, protože to by nebylo upočítatelné
- Compound scaling
 - Větší síť bude „násobkem“ (škálováním) základní sítě
 - Síť vyjádříme jako spojení s bloků, z nichž každý L_i -krát opakuje operaci $\mathcal{F}_i$

$$\mathcal{N} = \bigodot_{i=1 \dots s} \mathcal{F}_i^{L_i} (X_{\langle H_i, W_i, C_i \rangle}) \quad (1)$$

- Škálovat budeme uvnitř bloků, tj. síť bude mít stejný počet bloků, ty ale budou větší
- Musíme najít optimální poměr toho, jak moc má být větší hloubka (# vrstev), šířka (# filtrů ve vrstvách) a rozlišení (velikost konv. map)
- Zároveň chceme, aby větší verze měla cca 2x více FLOPs

EfficientNet (2019)

$$\begin{aligned}\text{depth: } d &= \alpha^\Phi \\ \text{width: } w &= \beta^\Phi \\ \text{resolution: } r &= \gamma^\Phi \\ \text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 &\approx 2 \\ \alpha \geq 1, \beta \geq 1, \gamma &\geq 1\end{aligned}$$

velikost sítě lze ovládat jediným parametrem Φ tak, že zvednutí jeho hodnoty o +1 zdvojnásobí FLOPs (viz podmínka)

- Základní síť EfficientNet-B0 má $\Phi = 0$
- Větší síť získáme
 - počet vrstev uvnitř každého bloku vynásobíme α -krát (a zaokrouhlíme)
 - počet filtrů konv. map vynásobíme β -krát
 - rozlišení vstupu zvětšíme γ -krát
- Neznáme hodnoty $\alpha, \beta, \gamma \rightarrow$ provedeme grid search přes různé kombinace, které splňují podmínku $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ a vybereme takovou, která maximalizuje skóre po natrénování přeškálované sítě (v článku vyšlo $\alpha = 1.2, \beta = 1.1, \gamma = 1.15$)
- Vznikne EfficientNet-B1, protože má $\Phi = 1$
- Další sítě až do EfficientNet-B6 získáme dosazením $\Phi = 2 \dots 6$ do škálovacího schématu

EfficientNet (2019)

Table 1. EfficientNet-B0 baseline network – Each row describes a stage i with $\hat{L}_i$ layers, with input resolution $\langle \hat{H}_i, \hat{W}_i \rangle$ and output channels $\hat{C}_i$. Notations are adopted from equation 2.

Stage i	Operator $\hat{\mathcal{F}}_i$	Resolution $\hat{H}_i \times \hat{W}_i$	#Channels $\hat{C}_i$	#Layers $\hat{L}_i$
1	Conv3x3	224×224	32	1
2	MBConv1, k3x3	112×112	16	1
3	MBConv6, k3x3	112×112	24	2
4	MBConv6, k5x5	56×56	40	2
5	MBConv6, k3x3	28×28	80	3
6	MBConv6, k5x5	14×14	112	3
7	MBConv6, k5x5	14×14	192	4
8	MBConv6, k3x3	7×7	320	1
9	Conv1x1 & Pooling & FC	7×7	1280	1






Figure 5. FLOPS vs. ImageNet Accuracy – Similar to Figure 1 except it compares FLOPS rather than model size.

Srovnání nejpoužívanějších CNN architektur



obrázek: [Canziani et al.: “An Analysis of Deep Neural Network Models for Practical Applications”](#)

Srovnání nejpoužívanějších CNN architektur



obrázek: [Canziani et al.: "An Analysis of Deep Neural Network Models for Practical Applications"](#)


Transfer learning

Trénování konvolučních sítí při málo datech

- Popsané architektury mají obvykle miliony parametrů
- Malé datasety na jejich trénování nestačí → výrazný overfit
- I pokud data máme: trénování VGG na ImageNet trvalo autorům 2-3 týdny, a to i s 4x NVIDIA Titan Black GPU
- **Naštěstí lze obejít!**
 1. Můžeme vzít existující již natrénovaný model (např. VGG-16)
 2. Odstraníme poslední klasifikační vrstvu
 3. Nahradíme vlastní

Transfer learning

1000 tříd pro ImageNet




ImageNet data

VGG16

poslední lineární vrstvu
tvaru 4096×1000
zahodíme

2 třídy: kočky vs psi



VGG16

připojíme vlastní lineární vrstvu
tvaru 4096×2 a náhodně
inicializujeme

pokud máme málo dat, je lepší
konvoluční vrstvy netrénovat →
layer freeze

můžeme použít vlastní data

Transfer learning v PyTorch

```
model_conv = torchvision.models.resnet18(pretrained=True)
```

```
for param in model_conv.parameters():  
    param.requires_grad = False
```

“zmrazení” vrstev, nebudou se trénovat a zůstávají konst. → síť pouze jako extraktor příznaků

```
# Parameters of newly constructed modules have requires_grad=True by default
```

```
num_ftrs = model_conv.fc.in_features  
model_conv.fc = nn.Linear(num_ftrs, 2)
```

poslední vrstvu klasifikující do 1000 ImageNet tříd nahradíme vlastní, která má pouze 2 třídy

```
model_conv = model_conv.to(device)
```

```
criterion = nn.CrossEntropyLoss()
```

jako seznam parametrů pro optimalizaci předáváme pouze poslední lineární vrstvu (pouze pro urychlení)

```
# Observe that only parameters of final layer are being optimized as  
# opposed to before.
```

```
optimizer_conv = optim.SGD(model_conv.fc.parameters(), lr=0.001, momentum=0.9)
```


- poté, co je poslední vrstva natrénovaná, je možné opět uvolnit (“rozmrazit”) i konvoluční vrstvy a model dále zlepšit (fine tuning)

https://pytorch.org/tutorials/beginner/transfer_learning_tutorial.html


CNN příznaky

- Výstup z posledních lineárních vrstev lze použít např. jako příznaky (tzv. FC7) → CNN jako “feature extractor”
- Např. VGG-16 předposlední vrstva má rozměr 4096
- Nad těmito příznaky je možné natrénovat libovolný klasifikátor, třeba i rozhodovací stromy/lesy, bayesovské klasifikátory, ...
- Lze také využít pro urychlení trénování: celý dataset projet sítí a pro každý obrázek uložit na disk FC7 příznaky
- Během trénování se pak nemusí znovu a znovu provádět dopředný průchod celou sítí, pouze těmi posledními

např. VGG-16:



Transfer learning: shrnutí



specifičtější příznaky
(obličeje, text, ...)

obecné příznaky
(hrany, bloby, ...)

	podobná data	odlišná data
málo dat	trénovat spíše jen poslední vrstvu	problém 😊
hodně dat	fine tune několika vrstev (lze ale i celou síť)	fine tune více vrstev nebo i celé sítě